

ФИО: Земцов Сергей Алексеевич

Вариант: 10

Задача: №2 (Обработка пропусков)

Набор данных: №2 (Wine dataset из sklearn)

Доп. требование: Построить скрипичную диаграмму (violin plot) для произвольной колонки.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import load_wine
```

ан1. Загрузка данных

```
wine = load_wine(as_frame=True)
df = wine.frame

print("Исходные данные (первые 5 строк):")
display(df.head())
```

Исходные данные (первые 5 строк):										
	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavanoids	nonflavanoid_phenols	proanthocyanins	color_intensity
0	14.23	1.71	2.43		15.6	127.0	2.80	3.06	0.28	2.29
1	13.20	1.78	2.14		11.2	100.0	2.65	2.76	0.26	1.28
2	13.16	2.36	2.67		18.6	101.0	2.80	3.24	0.30	2.81
3	14.37	1.95	2.50		16.8	113.0	3.85	3.49	0.24	2.18
4	13.24	2.59	2.87		21.0	118.0	2.80	2.69	0.39	1.82

ан2. Искусственное создание пропусков

(по примечанию к заданию)

```
np.random.seed(42)

# Количественный признак: alcohol
idx_q = np.random.choice(df.index, size=10, replace=False)
df.loc[idx_q, 'alcohol'] = np.nan

# Категориальный признак: создадим на основе alcohol
df['alcohol_cat'] = pd.cut(df['alcohol'],
                           bins=[0, 12.5, 13.5, 20],
                           labels=['low', 'medium', 'high'])

# Категориальный признак: добавим пропуски
idx_c = np.random.choice(df.index, size=5, replace=False)
df.loc[idx_c, 'alcohol_cat'] = np.nan

print("\nКоличество пропусков после создания:")
print("alcohol:", df['alcohol'].isna().sum())
print("alcohol_cat:", df['alcohol_cat'].isna().sum())
```

Количество пропусков после создания:
alcohol: 10
alcohol_cat: 14

ан3. Обработка пропусков

```
# Количественный признак – заполнение медианой
med = df['alcohol'].median()
df['alcohol'] = df['alcohol'].fillna(med)

# Категориальный признак – заполнение модой
mod = df['alcohol_cat'].mode()[0]
```

```
df['alcohol_cat'] = df['alcohol_cat'].fillna(mod)
```

```
print("\nПропусков после обработки:")
print("alcohol:", df['alcohol'].isna().sum())
print("alcohol_cat:", df['alcohol_cat'].isna().sum())
```

```
Пропусков после обработки:
alcohol: 0
alcohol_cat: 0
```

4. Визуализация: скрипичная диаграмма (violin plot)


для колонки alcohol, сгруппированной по target

```
plt.figure(figsize=(8, 6))

# Собираем данные по классам
classes = sorted(df['target'].unique())
data_for_violin = [df[df['target'] == c]['alcohol'].values for c in classes]

# Построение violinplot на чистом matplotlib
plt.violinplot(data_for_violin, positions=classes, showmedians=True)

plt.title('Распределение содержания алкоголя по классам вин (Violin Plot)')
plt.xlabel('Класс вина')
plt.ylabel('Alcohol')
plt.xticks(classes)
plt.grid(axis='y', alpha=0.5)
plt.show()
```



5. Выводы

```
print("""
Выводы:
- Для количественного признака alcohol использована медиана, т.к. она устойчива к выбросам.
- Для категориального признака alcohol_cat – мода, т.к. это наиболее частое значение.
- Для моделирования будут использованы все исходные числовые признаки (alcohol, malic_acid, ...),
  кроме искусственно созданного alcohol_cat, который добавлен только для демонстрации.
- Скрипичная диаграмма показывает заметную разницу в среднем содержании алкоголя
  для классов 0, 1 и 2 (класс 0 в целом имеет более высокие значения).
""")
```

```
Выводы:
- Для количественного признака alcohol использована медиана, т.к. она устойчива к выбросам.
- Для категориального признака alcohol_cat – мода, т.к. это наиболее частое значение.
- Для моделирования будут использованы все исходные числовые признаки (alcohol, malic_acid, ...),
  кроме искусственно созданного alcohol_cat, который добавлен только для демонстрации.
- Скрипичная диаграмма показывает заметную разницу в среднем содержании алкоголя
  для классов 0, 1 и 2 (класс 0 в целом имеет более высокие значения).
```

